CSV data cleaning: chalkashlikdan ishonchli datasetgacha

super_dirty_students.csv misolida 1000 qatorli ma’lumotni tozalash, standartlashtirish, parsing qilish va yakuniy QA nazoratidan o‘tkazish jarayoni.

1000
Asl qatorlar

18 → 38
Schema kengayishi

20
Yangi foydali ustun

0
Final duplicate

Slayd nimani ko‘rsatadi?

Audit | Cleaning | Parsing | QA

- “xom” CSV ichidagi format, missing va struktur muammolarini ko‘rsatadi
- 10 bosqichli tozalash pipeline qanday ishlaganini tushuntiradi
- oldin va keyin farqini real misollar va raqamlar bilan beradi
- dataset nega endi tahlil va hisobot uchun tayyor holatga kelganini isbotlaydi

Natija: oddiy “cleaning” emas, balki ma’lumot sifati boshqarilgan dataset.

Bitta qarashda asosiy natijalar

Slayd davomida shu natijalarning qanday olingani bosqichma-bosqich ko‘rsatiladi.

714
Invalid yoki bo‘sh email

371
Invalid yoki bo‘sh phone

814
JSON parse bo‘lgan qator

789
City/District ajratilgan

3/3
Numeric QA OK

Nima kuchaydi?

- dataset 18 ustundan 38 ustunga kengaydi
- murakkab JSON va address maydonlari tahlilga qulay ko‘rinishga keldi
- contact va numeric maydonlar validation qoidalari bilan nazorat qilindi

Nima uchun bu salmoqli?

- sonlar real datasetdan olingan va QA bilan tasdiqlangan
- faqat chiroyli slayd emas, qaror qabul qilish qiymati ko‘rsatildi
- cheklovlar ham yashirilmagan: missing contact ma’lumotlari yuqori bo‘lib qolgan

“Xom” dataset nega xavfli edi?

Muammo ko‘rinishda emas, qaror sifati darajasida ham mavjud edi.

Asosiy xavf

- bir xil ma’lumotlar turli yozuv ko‘rinishida saqlangan
- raqam, sana, email va telefon maydonlari standart emas edi
- murakkab JSON maydonlari oddiy tahlilda ko‘rinmaydigan holatda edi
- address maydoni uzun satr ko‘rinishida bo‘lib, segmentatsiya uchun qulay emas edi

Natijaviy xavf

- tahlil natijalari noto‘g‘ri guruhlanishi yoki buzilishi mumkin
- aloqa ma’lumotlarining sifati past bo‘lgani sabab real foydalanish cheklanadi
- dashboard va avtomatlashtirish uchun ishonchsiz poydevor yuzaga keladi
- foydalanuvchi faylni ko‘rsa ham, undagi ma’lumotga to‘liq ishona olmaydi

Dataset profili

Boshlang‘ich audit dataset hajmi, ustun tuzilmasi va semantik toifalar bo‘yicha yo‘l xaritasini berdi.

1000
Qatorlar soni

18
Asl ustunlar

38
Cleaned ustunlar

+20
Qo‘shimcha maydon

Semantik tasnif

- 9 ta string maydon: name, gender, city, email, course va boshqalar
- 6 ta numeric maydon: age, score, attendance, gpa, money_spent, student_id
- 2 ta date maydon: date_of_join va event_time
- 1 ta JSON maydon: profile_json

Auditdan chiqqan xulosa

- tozalash jarayonini “hamma ustunga bir xil qoidani qo‘llash” usulida emas, ustunma-ustun olib borish kerakligi aniqlandi
- eng katta muammo kontakt ma’lumotlari, yozuv variantlari va murakkab strukturadagi maydonlarda jamlangan

Boshlang‘ich audit: missing values tahlili

Missing qiymatlar keyingi fillna yoki ehtiyotkor bo‘sh qoldirish qarorlarining asosini berdi.

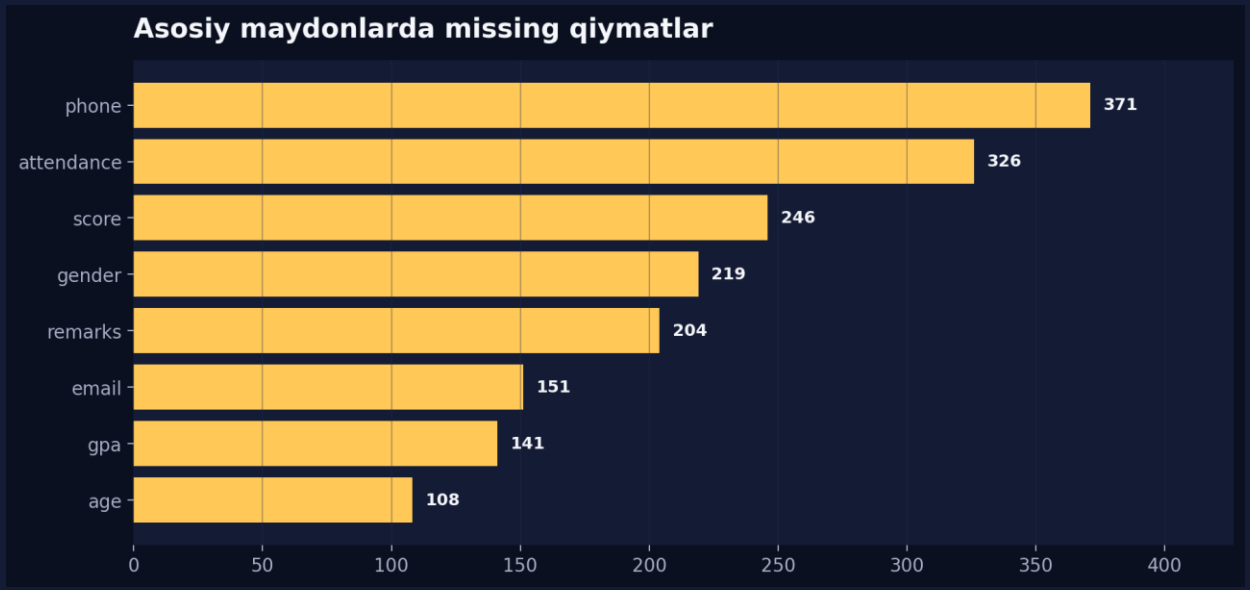

Nima ko‘rindi?

- gender, email va phone kabi maydonlarda bo‘sh qiymatlar sezilarli edi
- missing muammosi ayniqsa contact va identifikatsion sifatga ta’sir qilardi
- ba’zi maydonlarda yo‘qotishdan ko‘ra, noto‘g‘ri yozuvni topish muhimroq bo‘ldi

Eslatma: cleaned faylda email bo‘sh qiymatlari ko‘payganining sababi — noto‘g‘ri email formatlari ataylab NaN ga aylantirilgan.

01

Tozalash yadrosi

Endi 10 bosqichli pipeline qanday ishlaganini asosiy bloklar bo‘yicha ko‘ramiz.

- salmoqli mazmun berish uchun muammo, usul, natija va cheklovlar alohida ko‘rsatildi
- har bir blok real sonlar, amaliy qarorlar va tahlilga tayyor natijalar bilan bog‘landi
- maqsad: slaydlar chiroyli ko‘rinishi emas, himoyada ishoningan ta’sir uyg‘otishi

10 bosqichli pipeline

Texnik tafsilotlar soddalashtirilib, non-technical auditoriya uchun 4 fazaga yig‘ildi.

01 Audit

- CSV ochish
- 10 qator preview
- ustunlar va missing values
- type tushunchasi

02 Cleaning

- string strip
- numeric/date
- email/phone

03 Parsing

- JSON ochish
- flatten
- address ajratish

04 QA

- duplicate
- normalization
- final export
- quality checks

String ustunlar bilan ishlash

Bu bosqich ma’lumotning tashqi ko‘rinishini emas, bir xil ma’nodagi yozuvlarni yagona qoidaga bo‘ysundirdi.

Nima qilindi?

- matnli ustunlardagi ortiqcha bo‘sh joylar olib tashlandi
- bo‘sh stringlar NaN qiymatiga aylantirildi
- null ma’nosini beruvchi turli yozilishlar yagona bo‘sh qiymat sifatida qaraldi
- natijada bir xil ma’lumotlar turli ko‘rinishda tarqalib ketmasligi ta’minlandi

strip()
bo‘sh joylarni tozalash

NaN
bo‘sh string natijasi

1x
yagona talqin

Nima uchun bu muhim?

- guruhlash, qidirish va filterlashda bir xil qiymat bir nechta ko‘rinishga bo‘linmaydi
- keyingi normalizatsiya va validation bosqichlari ancha osonlashadi
- foydalanuvchi bir qarashda tartibli datasetni ko‘radi, lekin asosiy foyda — tahlil barqarorligida

Raqam va sana ustunlari qanday ishonchli qilindi?

Bu bosqich hisob-kitoblarni buzadigan "uncleaned" yozuvlarni tozalab, numeric va datetime tayyor holatga keltirdi.

Numeric ustunlar

- age, score, GPA, attendance va money_spent numeric formatga o‘tkazildi
- matn ichiga aralashib qolgan sonlar tozalab olindi
- mantiqsiz diapazonlar aniqlanib NaN yoki cheklangan qiymatlarga keltirildi
- int va float turlari ustun ehtiyojiga qarab qo‘llandi

0–100
score nazorati

0–4
GPA nazorati

≤100
attendance clip

Date ustunlar

- turli yozuv usullaridagi sana qiymatlari datetime ko‘rinishga o‘tkazildi
- timestamp ko‘rinishlari ham parse qilindi
- yakunda sanalar yagona YYYY-MM-DD HH:MM:SS formatida saqlandi
- vaqt bo‘yicha tahlil va filtrlar endi izchil ishlaydi

Natija: number va date maydonlari “ko‘rinadigan chiroy” emas, balki hisoblash ishonchliligi uchun tozalandi.

Email va phone validation

Kontakt maydonlari bo‘yicha asosiy foyda — noto‘g‘ri yozuvlarni yashirish emas, ularga ishonmaslikni aniq belgilashdir.

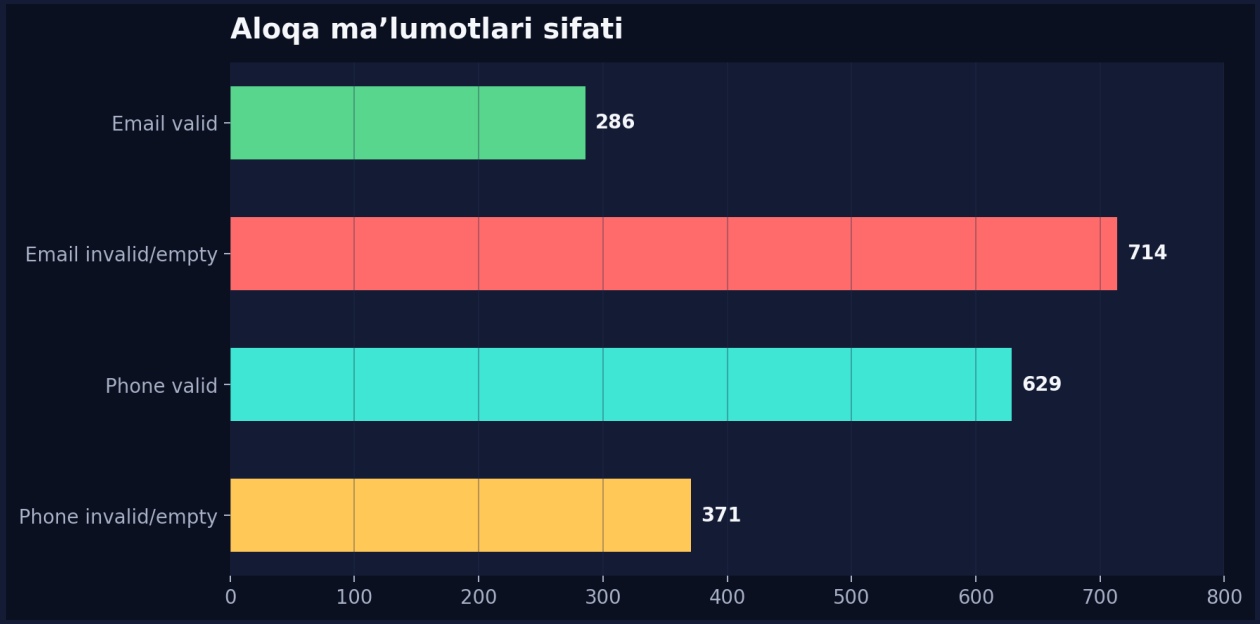

Amaliy xulosa

- invalid email qiymatlari bo‘sh holatga o‘tkazildi
- phone raqamlar yagona formatga keltirildi
- 286 ta email va 629 ta phone foydalanishga yaroqli deb topildi
- email sifati phone sifatidanga ancha past ekani ochiq ko‘rindi

Bu slide sifatsiz kontakt ma’lumotlarini “toza ko‘rsatish” emas, ularga real baho berilganini ko‘rsatadi.

02

Murakkab maydonlarni ochish

JSON va address maydonlari datasetning eng katta yashirin qiymatini tashkil qilardi.

- salmoqli mazmun berish uchun muammo, usul, natija va cheklovlar alohida ko‘rsatildi
- har bir blok real sonlar, amaliy qarorlar va tahlilga tayyor natijalar bilan bog‘landi
- maqsad: slaydlar chiroyli ko‘rinishi emas, himoyada ishoningan ta’sir uyg‘otishi

profile_json maydoni qanday ochildi?

Murakkab katak ichidagi ma’lumotlar tahlil qilinmaydigan blob bo‘lib qolmasligi uchun alohida maydonlarga ajratildi.

Ajratilgan asosiy bloklar

- hobbies
- skills
- family
- devices
- skills ichidagi python, excel, sql ko‘nikmalari
- family ichidagi siblings va income ko‘rsatkichlari
- devices ichidagi type, brand va year qiymatlari

814
parsed JSON

594
skills/device qamrov

14+
yangi JSON maydon

Nega bu salmoqli o‘zgarish?

- oldin bitta katak ichidagi ma’lumot endi ustunlar bo‘yicha ko‘rinadi
- tahlil qilish uchun qo‘lda JSON ochish shart bo‘lmaydi
- skills, family va devices bo‘yicha alohida filter va segmentlar tuzish mumkin bo‘ladi

Bu bosqich datasetni shunchaki tozalamaydi — uni boyitadi.

Yangi ajratilgan maydonlar qamrovi

Har bir yangi ustun 100% to‘lishi shart emas; muhim tomoni — foydali strukturani chiqarib olish muvaffaq bo‘lganidir.

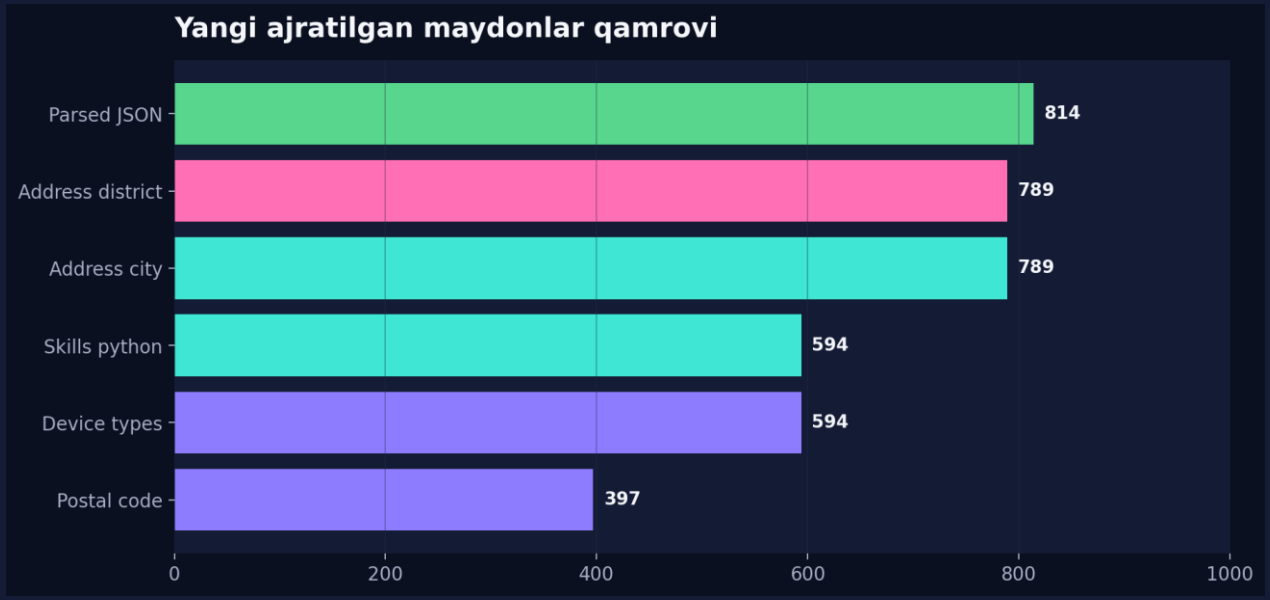

O‘qilishi

- 814 qator uchun JSON parsing muvaffaq bo‘lgan
- 789 qator uchun city va district ajratilgan
- postal code faqat mos format topilgan holatlarda chiqarilgan
- qamrov sonlari parsing qoidalarining amalda ishlaganini tasdiqlaydi

Course normalizatsiyasi: 10 yozuvdan 2 standart kategoriya

Bu slide bir xil ma’lumot turli yozilganda qanday chalkashlik tug‘ilishini aniq ko‘rsatadi.

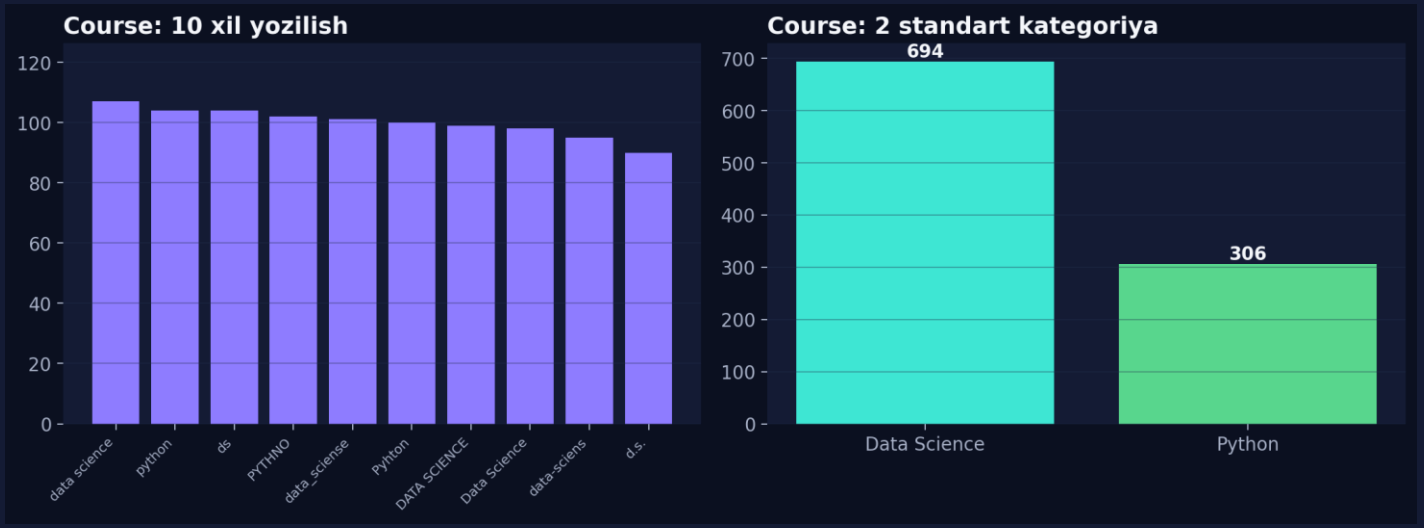

Natija

- tozalashdan oldin 10 xil course yozilishi bor edi
- tozalashdan keyin ular 2 standart kategoriya ostida jamlandi
- Data Science: 694
- Python: 306

Bu normalizatsiya bo‘lmasa, hisobot va guruhlash natijalari bo‘linib ketardi.

Gender normalizatsiyasi: 9 ko‘rinishdan 3 standart sinfga

Xatoli yozuvlar va bo‘sh qiymatlar bir xil qoidaga keltirilib, umumiy sifat oshirildi.

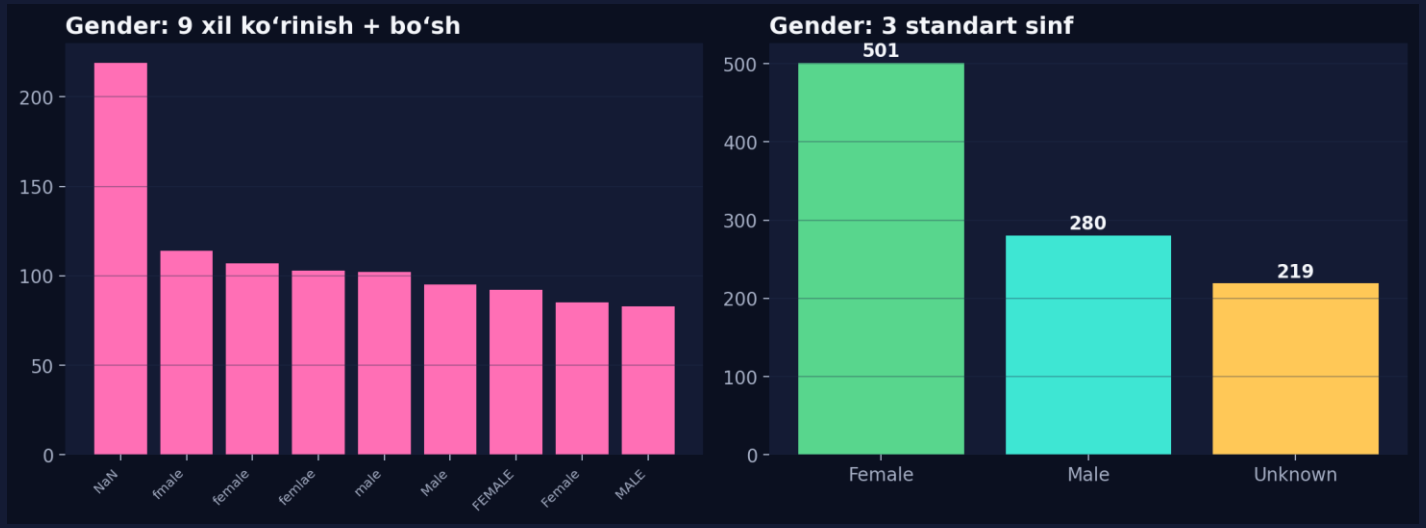

Standart natija

- Female: 501
- Male: 280
- Unknown: 219
- bo‘sh va xatoli yozuvlar endi nazorat ostida

Bu bosqich ma’lumotni “yoqimli ko‘rsatish” uchun emas, segmentlarni adolatli hisoblash uchun kerak bo‘ldi.

Final schema: 18 ustundan 38 ustungacha

Tozalash yakunida dataset nafaqat tartiblandi, balki yangi analitik maydonlar bilan boyidi.

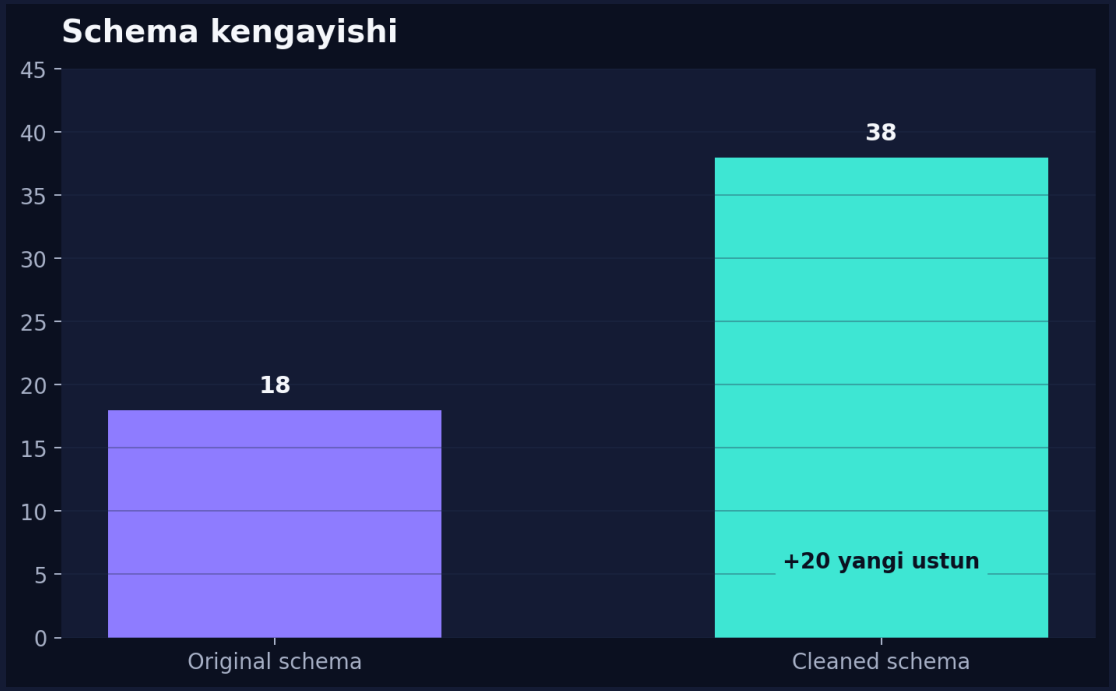

Yangi maydonlarning qiymati

- contact validation flaglari: email_valid, phone_valid
- JSON dan olingan skills, family, devices va hosilalari
- address parsing natijalari: addr_city, addr_district, addr_postal
- bu maydonlar kelajakdagi dashboard va analytics uchun to‘g‘ridan-to‘g‘ri ishlatiladi

QA natijalari: asosiy tekshiruvlar

Bu slaydda cleaning yakunidagi eng muhim nazorat natijalari jamlangan.

1000	1000	0	714	371	0
Original rows	Cleaned rows	Removed duplicates	Missing email	Missing phone	Final dup

Numeric QA

- GPA qiymatlari 0–4 oralig‘ida
- attendance qiymatlari 0–100 oralig‘ida
- score qiymatlari 0–100 oralig‘ida
- 3 ta asosiy numeric check muvaffaqiyatli o‘tgan

QA dan chiqadigan xulosa

- dataset hajmi saqlangan, lekin sifati oshgan
- error-prone qiymatlar nazorat ostiga olingan
- cleaned dataset keyingi analitik ishlatish uchun ancha xavfsizroq

VALUE

Amaliy qiymat: foydalanuvchi va biznes uchun

Kuchli taqdimotning asosiy talabi — texnik jarayonning real foydasini ko‘rsatish.

Foydalanuvchi uchun

- toza data faylni o‘qish va tushunishni osonlashtiradi
- hisobot tayyorlash va natijani tekshirish tezlashadi
- noto‘g‘ri talqin qilish xavfi kamayadi
- oddiy foydalanuvchi ham dataset bilan ishonchliroq ishlay oladi

Biznes uchun

- qaror qabul qilish uchun ishonchli data manbasi paydo bo‘ladi
- dashboard, monitoring va avtomatlashtirish uchun toza poydevor yaratiladi
- vaqt yo‘qotilishi va xatolik xavfi kamayadi
- data cleaning texnik ish emas, sifatli qaror tayyorlash jarayoniga aylanadi

Cheklovlar va keyingi qadamlar

Salmoqli Slayd faqat yutuqlarni emas, qolgan muammolarni ham aniq ko‘rsatadi.

Hali qolgan cheklovlar

- 714 ta email va 371 ta phone hali ham bo‘sh yoki yaroqsiz
- address parsing heuristic qoidalarga tayanadi, ya’ni universal emas
- data source sifati oshmasa, cleaning natijasi ham ma’lum chegaraga ega bo‘ladi

Tavsiya etiladigan keyingi qadamlar

- validation qoidalarini data kiritish bosqichining o‘ziga qo‘shish
- email va phone uchun source-level tekshiruvlarni kuchaytirish
- address va JSON parsing qoidalarini yangi namunalarga qarab boyitish
- cleaned dataset asosida dashboard yoki monitoring qatlamini qurish

Xulosa

Bu loyiha nimani isbotladi?

- data cleaning faqat tozalash emas, ma’lumot sifatini boshqarish jarayoni ekanini
- har bir ustun bilan alohida ishlash umumiy dataset sifati va ishonchliligini oshirishini
- yakunda foydalanuvchi uchun tushunarli, analitika uchun tayyor va himoyada ko‘rsatishga arziydigan natija olish mumkinligini

18 → 38
Schema transformatsiyasi

3/3 OK
Numeric QA natijasi

Tartibsiz CSV → nazoratdan o‘tgan, ishlatishga tayyor dataset.

CLOSING

To contact:

F.I.Sh : Sobitov Bunyodxon Yusufjon o‘g‘li

Aspiring Data Analyst | Python • SQL • Power BI | Dashboarding & Data Storytelling

LinkedIn: http://www.linkedin.com/in/bunyodxonsobitov

GitHub: https://github.com/SOBITOVB

Email: bunyodxonsobitov@gmail.com

Phone number: +998 94 030 49 64

Telegram: @b_sobitov